

1. 现代大语言模型Qwen/LLaMA架构中的 hidden state

Qwen 类模型通常采用 decoder-only、Pre-Norm、RoPE 架构。


一个 Qwen Block 可概括为：

$$x_l \rightarrow \text{RMSNorm} \rightarrow \text{Attention} \rightarrow +x_l \rightarrow \text{RMSNorm} \rightarrow \text{MLP} \rightarrow +\text{residual} \rightarrow x_{l+1}$$

$$x_{l+1}$$

即整个 Qwen Block 最上方残差加法后的输出，被视为该层的 block-level hidden state。

整个模型可以看成：



2. 一个模型的 Hidden State 能否直接给另一个模型

关键结论：

Hidden State 不是天然通用的“跨模型语言”

是否能直接工作取决于 Sender 和 Receiver 的表示接口是否兼容。

Sender → Receiver	是否可能直接工作	原因
同一模型，第 l 层 → 第 $l + 1$ 层	可以	本来就是模型正常 forward 的接口
同一模型，最后层 → 第一层	通常不合理	layer-space mismatch
不同模型，同层 → 同层	通常不可靠	latent coordinate system 不一致
不同模型 + adapter	更合理	学习 A→B 的表示映射

需要区分三种兼容性：

shape compatible $\neq$ distribution compatible $\neq$ functionally compatible

即使两个模型都有：

$$h_A, h_B \in \mathbb{R}^{4096}$$

也只说明 shape 一样，并不说明两个表示空间等价。

3. PD 分离中为什么主要传 KV Cache

在 Prefill–Decode Disaggregation 中，Prefill 节点处理 prompt 并构造各层 KV Cache：

$$\{K_l, V_l\}_{l=1}^L$$

然后 Decode 节点继续逐 token 生成。

原因是生成第 $T + 1$ 个 token 时，每层 Attention 都需要历史 token 的：

$$K_{1:T}^{(l)}, V_{1:T}^{(l)}$$

因此：

KV Cache 是标准 autoregressive decoding 所需的计算状态

而普通最后层 hidden state：

$$H^{(L)}$$

无法直接替代所有层的历史 KV。

4. 为什么只传最后一层 Hidden State 不能直接持续 Decode

如果电脑 A 拿到：

$$h_T^{(L)}$$

电脑 B 可以用 LM Head 算出一次 next-token logits：

$$\text{logits}_{T+1} = W_{\text{LM}} \text{Norm}(h_T^{(L)})$$

因此：

$$h_T^{(L)} \rightarrow \text{LM Head} \rightarrow x_{T+1}$$

这一小步可以。

但生成下一个 token 后，B 的第 1 层 Attention 就需要：

$$K_{1:T}^{(1)}, V_{1:T}^{(1)}$$

后续每层也需要对应 KV。

仅有：

$$h_T^{(L)}$$

无法恢复：

$$\{K_l, V_l\}_{l=1}^L$$

因此：

Last Hidden State $\neq$ 完整 Decoding State

所以：

- 标准 PD 分离：传 KV Cache；
- Pipeline Parallel：常传 hidden activation；
- Agent latent communication：可传 hidden-derived latent。