

1. 主要实验结果

实验设置

- 模型选择: QWEN2.5-1.5B instruct
- Sender depths: 0, 7, 14, 21, 28
- Receiver depths: 0, 7, 14, 21, 27
- Hidden size: 1536
- Latent variants: last 8, 16, 32, full, and evidence_span
- samples: 1000

QA任务示例:

Sender:

Private information:

Alice lives in Paris.

Bob lives in London.

Carol lives in Tokyo.

David lives in Rome.

Question:

Where does Carol live?

Receiver:

Question:

Where does Carol live?

A. Paris

B. London

C. Tokyo


D. Rome


Answer:

插入规则:


[Receiver question and options][Sender latent][\n\nAnswer:]







直接给出答案的 baseline(The correct answer is C):






正式实验







实验效果好的几个点:

Latent	Sender→Receiver	Accuracy	Delta use	Correct-Zero
evidence	0→0	0.864	0.603	0.615
full	0→0	0.707	0.454	0.459
last-32	0→0	0.695	0.434	0.446
last-16	0→0	0.360	0.131	0.111
evidence	7→7	0.381	0.150	0.143
last-32	7→7	0.405	0.139	0.184
full	7→7	0.390	0.126	0.168
last-32	14→7	0.319	0.065	0.098

这里 correct-zero 与 delta_use 方向一致，说明强结果不是单纯增加 latent token 或改变 position 引起的。

2. 长度提升本质上是 evidence coverage 提升

实际 private-context prompt 的 token 范围类似：

```
last-8:
.
Question:
Where does Nina live?
```

last-16:
...最后一到两条事实...
Question:
Where does Nina live?

last-32:
几乎完整的四条事实 + Question

因此：

- last-8 没有答案事实，整个热力图接近 chance 是合理的。
- last-16 偶尔覆盖目标事实，所以只有有限提升。
- last-32/full 基本覆盖全部事实，因此明显提升。
- evidence-span 只用平均约 5.57 个 token，却达到最高的 86.4%。

所以这里不能简单得出“latent 越长越好”，更准确的结论是：

latent 是否包含目标 evidence，比 latent token 数量更重要。

Evidence-span 是一个 oracle selector，结果证明“选择正确 token”比增加通信带宽更有效。

3. Depth 0 很强，但它接近文本注入

sender=0, receiver=0 时传递的是 token embedding。它基本等价于把对应文本作为连续 soft tokens 插入 Receiver，然后让它经过完整 28 层。

因此：

- evidence 0→0 的 86.4% 证明 evidence 提取和 Receiver prompt 都正确。
- 但它不能单独证明“深层 hidden-state communication”成立。

更有研究价值的是 7→7：

evidence: accuracy 0.381, delta_use 0.150
last-32: accuracy 0.405, delta_use 0.139
full: accuracy 0.390, delta_use 0.126

这说明经过前 7 层的 contextual hidden states，确实还能被另一个 Receiver 的第 7 层继续利用。

4. 有效区域不是完整对角线，而是左上角

Private-context 中：

- Receiver depth 0 最强。
- Receiver depth 7 次强。
- Receiver depth ≥ 14 时，绝大多数 Δ_{use} 接近 0。
- Sender depth 21/28 基本无法利用。

这说明决定性能的不只是“Sender 和 Receiver 层数匹配”，还有剩余计算量：

- Receiver depth 0：latent 后面还有 28 层。
- Receiver depth 7：还有 21 层。
- Receiver depth 14：只剩 14 层。
- Receiver depth 21/27：只剩 7 层或 1 层。

Evidence 需要完成“恢复城市 $\rightarrow$ 匹配选项 $\rightarrow$ 输出标签”，剩余层数太少时无法完成。

因此这次结果更支持：

Raw latent 需要足够多的下游 Transformer blocks 才能被解释，而不是只要 depth 相等就能直接兼容。

5. Baseline 结果说明 pipeline 正常

Baseline 的明显有效区域包括：

- $0 \rightarrow 0$ ：1.000
- $7 \rightarrow 0$ 、 $7 \rightarrow 7$ ：1.000
- $14 \rightarrow 0$ 、 $14 \rightarrow 7$ ：1.000
- $14 \rightarrow 14$ ：0.596， $\Delta_{\text{use}}=0.374$
- $21 \rightarrow 0$ ：1.000
- $21 \rightarrow 7$ ：0.751

这证明：

- 正确 latent 确实按 sample 注入。
- 固定 Answer：suffix 能读取 latent。
- shuffled mapping 工作正常。
- hidden state 中显式答案标签能够跨 forward 传递。

Baseline 呈现出近似三角形兼容区：通常 $\text{receiver_depth} \leq \text{sender_depth}$ ，同时 Receiver 必须保留足够多的剩余层。

但后期出现很强的负 Δ ，例如：

- $21 \rightarrow 21$ ：-0.121
- $28 \rightarrow 14$ ：-0.178

- 28→27: -0.209

这不太像普通统计噪声，而更像晚层表示不兼容：正确答案对应的 late hidden state 被注入后，反而系统性推动了错误选项。

《Enabling Agents to Communicate Entirely in Latent Space》的实验结果

Actor	Seen	Unseen
Ours Full	70.48 $\pm$ 1.01	65.42 $\pm$ 0.87
w/o curri	33.10 $\pm$ 2.97	20.65 $\pm$ 2.15
w/o $\mathcal{L}_{sep}$	58.81 $\pm$ 1.41	60.70 $\pm$ 5.50
w/o $\mathcal{L}_{align}$	56.90 $\pm$ 1.41	53.98 $\pm$ 3.35
w/o adapter	4.05 $\pm$ 1.70	4.48 $\pm$ 1.31

最终可以得出的结论

1. Hidden injection pipeline 已经通过 smoke 验证。
2. Private evidence 的使用具有明确因果性，因为 correct 显著高于 shuffled 和 zero。
3. Oracle evidence-span 是最有效率的通信方案。
4. 真正有意义的 intermediate transfer 出现在浅层，尤其是 7→7。
5. 中晚层没有表现不等于其中没有信息，只能说明未训练的 Receiver 无法直接利用这些 raw hidden states。
6. 下一步最值得研究的是 layer alignment、activation normalization 或轻量 adapter，而不是继续单纯增加 latent length。