

Communicating Activations Between Language Model Agents

Vignav Ramesh, Kenneth Li *Proceedings of the 42nd International Conference on Machine Learning*, PMLR 267:51094-51116, 2025.

第一部分：论文方法

1. 研究动机

传统多智能体语言模型通常使用自然语言通信：

Sender A → 生成文本消息 → tokenize → Receiver B → 生成答案

这种方式有两个问题：

1. **计算成本高**：sender 需要逐 token 解码消息，receiver 还要重新处理消息；
2. **信息压缩**：模型内部原本具有高维连续表示，但经过 LM Head 和离散 token 解码后，可能丢失一部分语义信息。

论文因此提出直接通过中间层 activation 通信，让 sender 不必先生成自然语言消息。

2. Activation Communication 的基本流程

设：

- A ：sender 模型；
- B ：receiver 模型；
- k ：sender activation 提取层；
- j ：receiver activation 注入层。

首先分别运行两个模型：

$$h_{A,k} = A_{\leq k}(x_A), \quad h_{B,j} = B_{\leq j}(x_B)$$

论文只使用两个序列**最后一个 token**的 activation：

$$a = (h_{A,k})_{\text{last}}, \quad b = (h_{B,j})_{\text{last}}$$

然后用函数 f 融合两者：

$$b' = f(a, b)$$

将 receiver 最后一个 token 的 activation 替换为 b' ，再让 B 从后续层继续前向传播并生成答案：

$x_A \rightarrow A$ 前向到第 k 层 → sender 最后 token activation a


↓

$x_B \rightarrow B$ 前向到第 j 层 → receiver activation $b \rightarrow f(a, b) \rightarrow B$ 后续层 → 答案

该方法不增加序列长度，不传输 KV cache，也不是将 activation 作为额外 token 拼接到输入中，而是直接修改 receiver residual stream 中已有位置的向量。

3. Activation 融合方式

Communicating Activations Between Language Model Agents



论文主要比较三种无需训练的融合函数：

$$\text{sum: } f(a, b) = a + b$$

$$\text{mean: } f(a, b) = \frac{a + b}{2}$$

$$\text{replace: } f(a, b) = a$$

其中 replace 最简单：

$$(h_{B,j})_{\text{last}} \leftarrow (h_{A,k})_{\text{last}}$$

论文实验发现 replace 通常优于 sum 和 mean。一个可能原因是 sum 会显著改变 activation 的范数和分布，而 replace 至少注入的是另一个真实模型产生的 activation。本周实验因此统一使用 $f=\text{replace}$ 。


如果两个模型的 activation 空间差异较大，论文还提出学习任务无关的线性映射矩阵 W ：

$$a' = Wa$$

再将 a' 注入 receiver。Vanilla AC 不需要额外训练； W 则是 model-pair-specific、task-agnostic 的可选模块。

原论文实验结果

Communicating Activations Between Language Model Agents



Communicating Activations Between Language Model Agents

Table 1: **Multi-player coordination games.** Sample (prompt, answer) pairs for each game.

Game	Sample Prompts & Ground-Truth Answer
Countries	x_A : “Alice is at the Acropolis of Athens.”
	x_B : “Which country is Alice located in?”
	B ’s Expected Answer: “Greece”
Tip Sheets	x_A : “Acme Inc. has taken a nosedive, as its quarterly earnings have dipped 8%. Meanwhile Doe LLC and Kiteflyer Labs have both reached record-high stock prices of 89, but Kiteflyer is involved in an IP lawsuit with its competitors.”
	x_B : “You must invest in one company out of {Acme Inc., Doe LLC, Kiteflyer Labs}. Which do you invest in?”
	B ’s Expected Answer: “Doe LLC”

Table 2: **Accuracies (%) on both coordination games using two identical LLaMA family models.** Communication at layer $k = j = 26$. 95% confidence intervals (1000 bootstrap iterations) reported in parentheses.

Model	Method	Accuracy (Countries)	Accuracy (Tip Sheets)
LLaMA-3.2-3B	$\mathbf{X}$	0.0 (0.0, 0.0)	38.6 (38.6, 39.4)
	SKYLINE	84.0 (83.5, 84.1)	100.0 (100.0, 100.0)
	NL	69.0 (68.7, 69.3)	74.3 (74.0, 74.6)
	AC (sum)	34.0 (33.9, 34.4)	50.0 (49.6, 50.3)
	AC (mean)	36.0 (35.5, 36.1)	80.0 (79.8, 80.4)
	AC (replace)	78.0 (77.7, 78.2)	90.0 (89.9, 90.3)
LLaMA-3.1-8B	$\mathbf{X}$	2.0 (1.9, 2.1)	54.3 (54.2, 54.5)
	SKYLINE	86.0 (85.7, 86.1)	100.0 (100.0, 100.0)
	NL	77.0 (76.6, 77.1)	85.7 (85.3, 85.8)
	AC (sum)	71.0 (70.9, 71.4)	85.7 (85.5, 86.0)
	AC (mean)	70.0 (69.7, 70.3)	92.9 (92.7, 93.1)
	AC (replace)	83.0 (82.7, 83.1)	95.7 (95.6, 95.9)

Method	Biog.	GSM8k	HS Psych.	Logic	Col. Bio.	Prof. Law	Pub. Rel.
3.2-3B	79.4±0.0	58.0±4.9	30.0±1.0	16.0±0.8	11.0±0.7	0.0±0.0	26.0±0.1
3.1-8B	83.9±0.0	60.0±4.9	65.0±0.1	42.0±0.1	50.0±0.2	20.0±0.8	53.0±0.2
NLD	80.2±0.1	75.0±4.3	83.0±0.8	37.0±0.1	71.0±0.1	30.0±0.1	63.0±0.7
AC	84.6±0.0	64.0±4.8	85.0±0.8	47.0±0.1	78.0±0.9	30.0±0.1	74.0±0.1
AC (W)	86.8±0.0	66.0±4.8	70.0±0.1	35.0±0.1	79.0±0.9	45.0±0.1	63.0±0.1

第二部分：本周实验

实验设置

项目	设置
Sender model	Qwen2.5-1.5B-Instruct
Receiver model	Qwen2.5-1.5B-Instruct
数据集	TipSheets
测试样本数	500
通信函数	replace
解码方式	greedy, do_sample=False
Sender 层范围	$k = 14, \dots, 27$
Receiver 层范围	$j = 14, \dots, 27$
网格规模	$14 \times 14 = 196$ 个组合

TipSheets 的 sender 接收公司相关 tip sheet，receiver 只看到投资选择问题，需要依赖通信获得 private context。

指标说明

本周同时报告两种指标：

- 1. **开源仓库指标：** 使用当前仓库的 token F1-match，F1 大于 0.5 即判为正确；
- 2. **严格单选指标：** 回复中必须只出现一个完整候选项，并且该候选项等于标准答案；包含多个候选项一律判错。

基线实验

方法	分数
Silent / no communication	0.298
Skyline（单模型同时看到两侧信息）	0.514
Natural Language Communication	0.452

基线含义：

- **Silent** 表示 receiver 不接收 sender 信息，是效果下界；
- **Skyline** 将完整信息直接提供给单个模型，是当前设置下的参考上界；
- **NLD(Duetal., 2023)** 表示 sender 先生成自然语言消息，再交给 receiver。

Improving Factuality and Reasoning in Language Models through Multiagent Debate

Yilun Du
MIT CSAIL
yilundu@mit.edu


Shuang Li
MIT CSAIL
lishuang@mit.edu

Antonio Torralba
MIT CSAIL
torralba@mit.edu

Joshua B. Tenenbaum
MIT CSAIL, BCS, CBMM
jbt@mit.edu

Igor Mordatch
Google Brain
imordatch@google.com

14×14 宽松F1指标热力图




主要现象：

- 全部 196 个格点均完成；
- 平均值为 0.288，中位数为 0.307；

- 最大值出现在 21→25，官方分数为 0.546；
- j=25-27 区域出现较强的不稳定性，部分组合异常升高，部分组合接近完全失效；
- 对角线 $k = j$ 平均约为 0.310，整体稳定但提升有限。

仅观察宽松F1指标时，21→25=0.546 甚至超过 skyline 0.514。但后续逐样本分析发现，这一高分主要来自模型同时输出多个候选项，被宽松 F1-match 误判为正确，因此不能解释为有效单选通信。

14×14 严格单选热力图



严格指标统计：

统计量	F1指标	严格单选指标
平均值	0.288	0.281
中位数	0.307	0.305
最大值	0.546	0.390
官方/严格完全一致的格点	151/196	151/196

主要异常点

$k \rightarrow j$	F1指标	严格指标	差值
21→25	0.546	0.114	0.432
19→25	0.400	0.216	0.184
18→27	0.318	0.146	0.172
16→25	0.336	0.202	0.134

其中 21→25 的 correct 和 shuffled 都容易枚举多个候选公司，因此官方高分不是正确样本 activation 所带来的语义增益。

严格指标最佳候选层组合

排名	$k \rightarrow j$	F1指标	严格指标	相对 silent
1	19→17	0.390	0.390	+0.092
2	19→22	0.372	0.372	+0.074
3	20→23	0.374	0.368	+0.070
4	18→17	0.366	0.366	+0.068
5	19→23	0.360	0.354	+0.056

从列均值看， j=17、22、23 是较稳定的 receiver 注入位置； j=25-27 整体更容易出现格式异常或性能崩塌。从行分布看， k=19 形成了最明显的局部高分带。

与基线的综合比较

方法	严格/可解释分数	相对 silent
Silent	0.298	—
Self control（官方AC路径）	0.306	+0.008
Shuffled activation	0.324	+0.026
Correct AC，19→17	0.390	+0.092
Natural Language Communication	0.452	+0.154
Skyline	0.514	+0.216

当前 AC 尚未超过 NLD 和 skyline，但已经将 silent 的 0.298 提升至严格单选 0.390，绝对提升 9.2 个百分点。更重要的是，correct 显著优于 shuffled 与 self，说明提升具有样本相关性。