KG-EmPress System

在前一章节中，本文围绕 EQA 任务，系统地阐述了基于认知知识库（Cognitive KB）的高层语义抽取与三元组传输机制。通过将自然语言问题与多模态感知结果统一映射为语义三元组，并依据其在认知 KB 中的已知性进行区分传输，系统能够在保证语义一致性的前提下显著降低通信冗余。然而，上述机制主要关注“传什么语义”以及“传哪些语义单元”，尚未涉及这些语义单元在物理信道中如何进行高效、鲁棒的表示与传输。为此，本章进一步从通信系统实现的角度出发，构建一个语义压缩与传输框架，重点研究连续语义表示的生成、压缩、量化及其在噪声信道下的联合优化问题，从而实现从高层语义决策到低层物理传输的完整闭环。

1 系统整体架构

本系统由实体嵌入、发送端（语义编码器）、信道、接收端（语义解码器）和实体重建与语义应用五个模块组成。

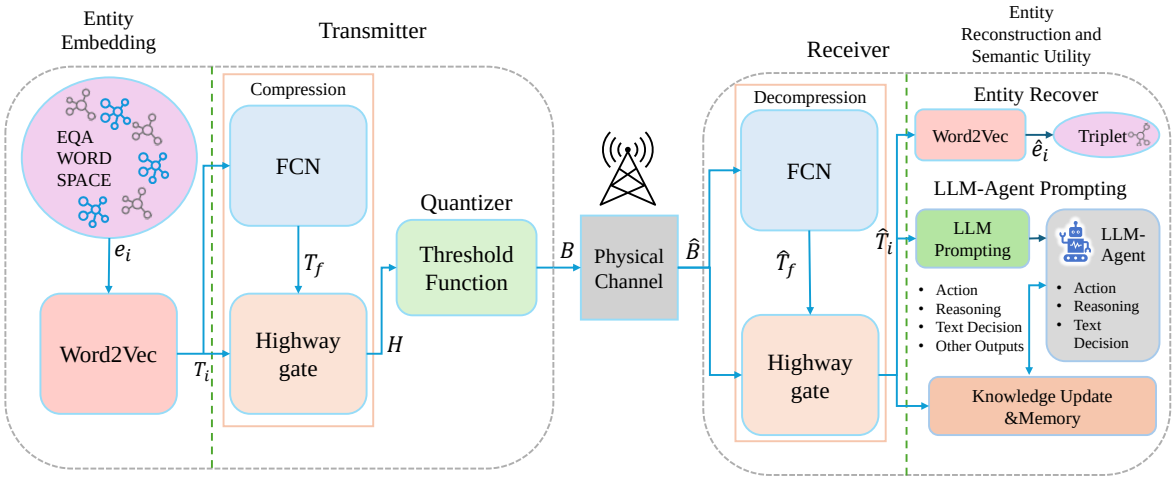


图 1: 语义压缩-传输系统总体架构示意图

图1 展示了本文提出的语义压缩–传输系统的整体架构，各功能模块含义如下。

1）实体嵌入模块（Entity Embedding）： EQA WORD SPACE 中的实体 e_i 首先通过 Word2Vec 模型映射至连续语义空间，得到初始语义表示 T_i。该模块将离散符号实体映射为可用于神经网络处理的连续向量，并作为后续语义压缩与传输的输入。

2）发送端模块（Transmitter）： 发送端由全连接网络（FCN）与高速公路网络（Highway Gate）构成，用于对输入语义向量进行非线性特征变换与压缩，得到压缩后的语义表示 H，随后压缩后的语义向量经阈值函数进行量化映射。该模块实现了语义层面的特征提取，维度压缩与向量量化，为后续低带宽传输提供基础。

3) 物理信道模块（Physical Channel）：可传输的比特流 B，并通过物理信道进行传输。信道引入的噪声与衰落效应统一建模于物理信道模块中，接收端获得受扰比特流 $\hat{B}$。

4) 接收端模块（Receiver）：接收端结构与发送端对称，由 FCN 与 Highway Gate 组成，对接收到的比特流进行反量化与语义重构，恢复得到连续语义表示 $\hat{T}_i$。该模块的训练目标是最小化原始语义表示 T_i 与重构语义表示 $\hat{T}_i$ 之间的重构误差，以保证语义空间的一致性。

5) 实体重建与语义应用模块（Entity Reconstruction and Semantic Utility）：该模块以重构语义表示 $\hat{T}_i$ 为输入，支持多种下游语义应用方式，包括：

- **实体恢复（Entity Recovery）：**通过 Word2Vec 逆映射或最近邻搜索方式，将 $\hat{T}_i$ 映射回实体空间，获得重构实体 $\hat{e}_i$，并用于三元组恢复与知识图谱推理任务；
- **大模型智能体提示（LLM-Agent Prompting）：**将 $\hat{T}_i$ 直接作为结构化语义状态输入至大语言模型智能体，实现推理、决策与文本生成等高层语义任务；
- **知识更新与记忆（Knowledge Update & Memory）：**将 $\hat{T}_i$ 写入外部记忆或知识库，用于长期知识更新、个性化建模及后续语义检索。

通过上述设计，系统不仅支持传统的实体级语义恢复任务，还能够面向智能体协同与多样化语义应用场景，实现面向任务的语义通信。

2 实体嵌入

2.1 选型依据

本文选用 Word2Vec 框架下的 Skip-gram 模型对知识图谱实体进行嵌入建模，主要基于其实现复杂度低、训练解耦性强以及良好的工程扩展性。Word2Vec 属于成熟且轻量级的嵌入方法，可在不引入复杂网络结构的前提下高效生成连续语义表示，降低系统整体实现成本。同时，该方法支持“两阶段独立训练”范式，实体嵌入可离线预训练，语义压缩与传输模块在固定嵌入空间上独立优化，从而避免联合训练带来的不稳定性与算力开销。此外，Word2Vec 生成的语义向量具备较好的可解释性，且在推理阶段仅涉及向量查表与相似度计算，资源需求低、计算效率高，适合作为语义通信系统的语义源表示方式。

2.2 构建流程

实体嵌入作为语义源信号，相当于语义空间中的连续语义表示，是语义通信系统的核心输入。

知识图谱以三元组形式存储，每个三元组表示为 $u_k = (e_{1k}, r_k, e_{2k})$，其中 e_{1k} 和 e_{2k} 分别表示头实体与尾实体，r_k 表示实体间的关系。本文中将家居语义空间记为 $\mathcal{U} = \{u_k\}_{k=1}^{N}$，其中 N 为三元组总数。由此可定义实体集合为

$$\mathcal{E} = \{e \mid e = e_{1k} \text{ 或 } e = e_{2k},\ \forall u_k \in \mathcal{U}\}. \tag{1}$$

采用 Word2Vec 的 Skip-gram 模型训练实体嵌入。对于中心实体 e_c 和上下文实体 e_o，条件概率定义为

$$p(e_o \mid e_c; \theta) = \frac{\exp(\mathbf{v}_{e_o}^{\top} \mathbf{v}_{e_c})}{\sum_{e \in \mathcal{E}} \exp(\mathbf{v}_{e}^{\top} \mathbf{v}_{e_c})}. \tag{2}$$

其中 $\mathbf{v}_e \in \mathbb{R}^D$ 表示实体 $e \in \mathcal{E}$ 的嵌入向量（$D = 300$），v_{e_c} 和 v_{e_o} 分别为中心实体 e_c 和上下文实体 e_o 的嵌入

Skip-gram 通过最大化知识图谱中实体对的条件似然实现训练，其优化目标为

$$\max_{\theta} \sum_{u_k \in \mathcal{U}} \log p(e_{2k} \mid e_{1k}; \theta). \tag{3}$$

训练完成后，每个实体被映射到稠密向量空间，并对其嵌入向量进行 L_2 归一化：

$$T_i = \frac{\mathbf{v}_e}{\|\mathbf{v}_e\|_2}, \quad e \in \mathcal{E}. \tag{4}$$

归一化后的向量 $T_i \in \mathbb{R}^D$ 作为语义通信系统的输入。

假设重建后的连续语义向量为 $\hat{T}_i$，重建实体为 $\hat{e}_i$，在接收端维护与发送端一致的实体嵌入词库，将 $\hat{T}_i$ 映射回离散实体空间的步骤可抽象表示为：

$$\hat{e}_i = \text{query}(\hat{T}_i), \tag{5}$$

其中 query$(\cdot)$ 表示在实体嵌入词库中的检索函数，其输出 $\hat{e}_i$ 为与 $\hat{T}_i$ 在语义空间中最为接近的实体。

3 发送端

发送端模块的目标是将高维连续语义向量压缩为低维离散表示，同时最大限度地保留其核心语义信息。该模块由两个级联子模块组成：**语义压缩模块**和**语义量化模块**。

3.1 语义压缩

输入 $T_i \in \mathbb{R}^D$ 首先经过全连接层（FCN）进行非线性变换：

$$T_f = \text{ReLU}(T_i W_f + b_f) \tag{6}$$

其中该层的权重矩阵 $W_f \in \mathbb{R}^{D \times K}$，偏置向量 $b_f \in \mathbb{R}^K$，输出 $T_f \in \mathbb{R}^K$ 是初步提取的语义特征表示，D 代表输入维度，K 代表压缩维度。

随后通过高速公路网络（Highway Network）进行自适应信息融合。高速公路网络允许模型在深层结构中穿越多跳线性路径，从而提升表达能力。变换门 G 由 Sigmoid 函数计算得到：

$$G = \sigma(T_i W_g + b_g) \tag{7}$$

其中 $W_g \in \mathbb{R}^{D \times K}$ 和 $b_g \in \mathbb{R}^K$ 是变换门的可学习参数。高速公路输出为：

$$H = G \odot T_f + (1 - G) \odot T_i W_a \tag{8}$$

其中 $W_a \in \mathbb{R}^{D \times K}$ 是用于维度对齐的可学习参数。Sigmoid 函数将输出限制在 $(0, 1)$ 区间，使得 G 可以作为" 门控信号"。这种门控机制使网络能够在不同维度上自适应地选择保留原始信息或利用变换特征，从而有效缓解梯度消失问题。

3.2 语义量化

语义量化模块的目标是将连续的浮点向量 H 转换为离散的二值向量 B，从而实现极致的信息压缩。因此，每个浮点数（32 位）被压缩为 1 比特。量化模块将连续向量 $H \in \mathbb{R}^K$ 转换为二值向量 $B = [b_1, b_2, ..., b_K]^\top \in \{0, A\}^K$，实现压缩（压缩比 32:1）。量化函数定义为：

$$b_i = \begin{cases} A, & \text{if } H_i \geq q_{th} \\ 0, & \text{otherwise} \end{cases} \tag{9}$$

其中，H_i 代表着 H 的第 i 个维度向量，量化函数门限 q_{th} 被设计为 H_i 在 K 个维度下的平均值。

$$q_{th} = \frac{1}{K} \sum_{i=1}^{K} H_i \tag{10}$$

量化后的向量 B 首先转换为标准二进制比特序列，再通过 Gray 编码 16-QAM 调制映射为复数信号，随后进入无线物理信道。

4 物理信道

为模拟实际数字无线通信中的调制、传输和解调过程，本文在语义量化模块与语义解码模块之间引入基于格雷编码（Gray coding）的 16 阶正交幅度调制（16-QAM）及无线信道模型。完整的物理层传输过程包括二进制映射、16-QAM 调制、信道传输、信道均衡和解调判决。

4.1 16-QAM 调制与功率归一化

对于语义量化模块输出的二值向量 $B \in \{0, A\}^K$，首先将其转换为标准二进制比特序列：

$$c_i = \frac{b_i}{A}, \quad c_i \in \{0, 1\}. \tag{11}$$

随后将比特序列按照每 4 比特一组进行划分。调制后的复数符号数为 $M = \lceil K/4 \rceil$。

本文采用 Gray 编码实现 16-QAM 映射。每组 4 比特中的前 2 比特映射至同相分量（I），后 2 比特映射至正交分量（Q）。每个分量使用以下 Gray 映射关系：

$$g(u, v) = -3 + 6u + 2v - 4uv, \quad u, v \in \{0, 1\}. \tag{12}$$

该映射将比特对 $\{00, 01, 11, 10\}$ 依次映射为幅度电平 $\{-3, -1, +1, +3\}$。

因此，第 m 个 16-QAM 符号表示为：

$$s_m = \frac{1}{\sqrt{10}} \left[g(c_{4m-3}, c_{4m-2}) + j g(c_{4m-1}, c_{4m}) \right], \tag{13}$$

其中 $j = \sqrt{-1}$，$m = 1, 2, \ldots, M$，c_i 表示补零后的比特序列。

对于等概率 16-QAM 星座，其未归一化的平均符号能量为 10。因此，采用 $1/\sqrt{10}$ 进行星座归一化，使参考平均符号能量满足 $E_{s,\text{ref}} = 1$。

4.2 无线信道与信噪比定义

经过 16-QAM 调制后，复数符号通过无线信道传输。本文采用统一的乘性衰落与加性噪声模型：

$$y_m = h_m s_m + n_m, \tag{14}$$

其中 s_m 为发送的复数调制符号，y_m 为接收符号，h_m 为复数信道系数，n_m 为加性复高斯白噪声，满足

$$n_m \sim \mathcal{CN}(0, N_0). \tag{15}$$

对于 AWGN 信道，设定 $h_m = 1$。对于 Rayleigh 衰落信道，设定

$$h_m \sim \mathcal{CN}(0, 1), \tag{16}$$

其中不同符号的信道系数独立生成，且满足 $\mathbb{E}[|h_m|^2] = 1$。因此，信道系数的幅度 $|h_m|$ 服从 Rayleigh 分布。

本文将 SNR 定义为归一化参考符号能量与复高斯噪声功率之比：

$$\mathrm{SNR}_{\mathrm{dB}} = 10 \log_{10} \left(\frac{E_{s,\mathrm{ref}}}{N_0} \right). \tag{17}$$

由于 $E_{s,\mathrm{ref}} = 1$，噪声功率可表示为：

$$N_0 = 10^{-\mathrm{SNR}_{\mathrm{dB}}/10}. \tag{18}$$

噪声的实部和虚部分别独立采样自 $\mathcal{N}(0, N_0/2)$。通过调整 N_0 模拟不同 SNR 条件下的无线传输环境。

4.3 信道均衡与 16-QAM 解调

在接收端，本文假设接收机能够准确获取信道状态信息（CSI），并采用零迫（Zero-Forcing, ZF）均衡恢复调制符号。均衡后的接收信号为：

$$\widetilde{y}_m = \frac{y_m}{h_m + \varepsilon}, \tag{19}$$

其中 ε 为防止除零的极小正数。对于 AWGN 信道，$h_m = 1$。

随后，接收端根据均衡符号与 16 个标准星座点之间的欧氏距离进行可微分软解调。设归一化 16-QAM 星座集合为 $\mathcal{S} = \{s^{(1)}, \ldots, s^{(16)}\}$，则第 m 个接收符号与第 l 个星座点的距离为：

$$d_{m,l} = \left| \widetilde{y}_m - s^{(l)} \right|. \tag{20}$$

使用 Softmax 函数计算各星座点的软分配权重：

$$p_{m,l} = \frac{\exp(-d_{m,l}/\tau)}{\sum_{r=1}^{16} \exp(-d_{m,r}/\tau)}, \tag{21}$$

其中 $\tau > 0$ 为控制软判决平滑程度的温度参数。

设 $\gamma_{l,k} \in \{0,1\}$ 表示第 l 个星座点对应 Gray 编码的第 k 位，则第 m 个接收符号的第 k 位软判决值为：

$$\bar{c}_{m,k} = \sum_{l=1}^{16} p_{m,l}\gamma_{l,k}, \quad k = 1,2,3,4. \tag{22}$$

随后通过阈值判决恢复二进制比特：

$$\hat{c}_{m,k} = \begin{cases} 1, & \bar{c}_{m,k} > 0.5, \\ 0, & \text{otherwise}. \end{cases} \tag{23}$$

为保证硬判决操作能够参与端到端训练，本文采用直通估计器（Straight-Through Estimator, STE）近似传递反向梯度。

最后，将恢复的比特序列去除补零部分，并按照原量化幅度 A 重新映射：

$$\hat{b}_i = A\hat{c}_i, \quad i = 1,2,\ldots,K. \tag{24}$$

由此得到恢复的二值语义表示 $\hat{B} \in \{0,A\}^K$，作为后续语义解码网络的输入。

5 接收端

接收端首先对物理信道输出的复数信号进行信道均衡、16-QAM 软解调和硬判决，从而恢复量化语义向量 $\hat{B} \in \{0,A\}^K$。随后，语义解码网络以 $\hat{B}$ 作为输入，采用与发送端相对应的全连接层和高速公路网络进行特征重建，最终恢复原始维度的连续语义表示 $\hat{T}$。发送端与接收端的神经网络参数相互独立。

$$\hat{T}_i = \text{decoder}(\hat{B}) \tag{25}$$

全连接层输出：

$$\hat{T}_f = \text{ReLU}(\hat{B}\hat{W}_f + \hat{b}_f), \tag{26}$$

其中 $\hat{W}_f \in \mathbb{R}^{K\times D}$、$\hat{b}_f \in \mathbb{R}^D$，$D$ 为原始语义向量的维度。

高速公路网络输出：

$$\hat{G} = \sigma(\hat{B}\hat{W}_g + \hat{b_g}) \tag{27}$$

$$\hat{T}_i = \hat{G} \odot \hat{T}_f + (1-\hat{G}) \odot \hat{B}\hat{W}_a, \tag{28}$$

其中 $\hat{W}_a \in \mathbb{R}^{K\times D}$，$\hat{G}$ 为门控，$\hat{W}_g$，$\hat{b_g}$ 为可学习参数。

高速公路网络的输出即为解码器的最终估计语义向量 $\hat{T}_i \in \mathbb{R}^D$ ，同时也是对原始语义向量 T_i 的重建估计。

特别注意的是，在前面章节中所采用的阶跃量化函数属于非连续映射，其导数在几乎所有定义域内均为零，这将导致基于反向传播的梯度更新机制失效。为克服该问题，本文引入**直通估计器（Straight-Through Estimator, STE）**机制，在保证前向传播执行真实量化操作的同时，通过近似手段恢复反向传播的梯度信息。

量化前的连续语义表示为 H，经信道传输与噪声扰动后得到的接收量化向量为 $\hat{B}$，其为原始二值向量 B 的失真版本。在前向传播阶段，解码器以 $\hat{B}$ 作为输入进行语义重构；而在反向

传播阶段，利用 STE 将不可导的量化与信道扰动过程近似为恒等映射，使梯度能够绕过 $\hat{B}$ 并直接作用于连续变量 H。

系统以重构语义向量与原始语义向量之间的均方误差（Mean Squared Error, MSE）作为训练目标，其损失函数定义为

$$L = \mathrm{MSE}\Big(T_i, \mathrm{decoder}\Big(H + \mathrm{sg}\Big[\hat{B} - H\Big]\Big)\Big), \tag{29}$$

其中 T_i 表示原始连续语义表示，$\mathrm{decoder}(\cdot)$ 为语义解码网络，$\mathrm{sg}[\cdot]$ 表示停止梯度算子（stop-gradient）。

在前向传播过程中，

$$H + (\hat{B} - H) = \hat{B},$$

因此网络实际使用的是信道输出的失真语义比特进行重构；而在反向传播阶段，由于 $\mathrm{sg}[\cdot]$ 阻断了 $\hat{B}$ 对梯度的影响，梯度仅通过连续变量 H 传播，从而避免了量化与信道模型不可导所带来的训练困难。

上述内容介绍了一种面向知识图谱的语义压缩与传输框架(KG-EmPress)。系统以 Word2Vec 生成的连续实体嵌入 T_i 作为语义源，经发送端 FCN 与 Highway 网络实现非线性压缩得到低维表示 H，并通过阈值量化映射为二值向量 B，将每维表示由 32 bit 压缩至 1 bit。量化比特经 AWGN/瑞利信道传输后得到 $\hat{B}$，接收端采用对称结构重构语义向量 $\hat{T}_i$。为克服量化与信道模型不可导问题，引入直通估计器（STE）实现训练。重构语义可用于实体恢复、智能体提示及知识更新，形成从高层语义到物理传输的完整闭环。

6 仿真

6.1 实验设置

本节对语义通信系统的模型配置、训练参数以及信道与调制环境进行说明，以保证实验结果的可重复性与可比性。

6.1.1 模型与训练参数

语义编码器与解码器均采用全连接层与高速公路网络构成的架构，其训练与推理过程中所使用的主要超参数设置如表 1 所示。

6.1.2 信道与调制参数

为评估模型在不同信道条件下的稳健性，实验中模拟了 AWGN 与 Rayleigh 信道，并在 (0-25dB) 范围以 2dB 间隔的不同信噪比下进行传输测试, 具体参数如表 2所示。

表 1: 基础模型参数设置

参数名称	符号	设定值 / 说明
输入维度	D_{in}	300（Word2Vec 预训练实体嵌入维度）
输出维度	D_{out}	**200**（可变，用于测试不同压缩率）
训练轮数	Epochs	1000（模型收敛训练轮数）
学习率	lr	0.01（Adam 优化器学习率）
量化幅度	A	1（二值量化的非零幅度）
数据划分	Ratio	7:3（训练集：测试集）

表 2: Experimental configurations of semantic communication and traditional baselines

Method	**Source Coding**	**Channel Coding**	**Modulation**	**Neural Architecture**
ASCII(UTF-8)+ LDPC	ASCII(UTF-8) fixed-length	LDPC (512, $\frac{5}{8}$, BP)	16-QAM	–
KG-SC	–	–	16-QAM	Dense + Pooling + linear(binary quant).
KG-EmPress(Ours)	–	–	16-QAM	FCN + Highway + STE binary quant.

Baseline 1: ASCII(UTF-8)+LDPC 传统通信方案. 该基线采用传统分层通信架构，将实体名称首先通过 UTF-8 编码映射为定长 ASCII 比特流，随后使用 $(512, 5/8)$ 码率的 LDPC 编码器进行信道编码，并基于 16-QAM 调制方式在物理信道中传输。该方案完整遵循“信源编码–信道编码–调制”的经典通信链路，作为无语义感知能力的参考系统，用于衡量传统通信在语义恢复任务下的性能下限。

Baseline 2: KG-SC 语义通信方案. KG-SC 为基于知识图谱嵌入的语义通信方法，其通过 Dense + Pooling + Linear 结构对实体嵌入进行连续语义压缩，并采用二值化量化实现信息传输，调制方式同样为 16-QAM。与传统通信相比，该方案省略显式信道编码模块，利用神经网络完成联合语义压缩与抗噪映射，是一种典型的深度语义通信基线方法。

6.2 评估指标

保真度（Fidelity）度量重建向量的信号质量：

$$F_i = 1 - \frac{||T_i - \hat{T}_i||_2^2}{||T_i||_2^2} \tag{30}$$

Recall@k 度量语义保留能力。本研究采用欧氏距离检索相似实体，这是知识图谱嵌入常用的语义一致性判定方式。对于重建向量 $\hat{T}_i$，在测试集中检索距离最近的 k 个原始向量，如果真身 T_i 在其中则命中：

$$\text{Recall@k} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{1}(rank_i \le k) \tag{31}$$

其中 $\mathbf{1}(\cdot)$ 是指示函数，如果条件成立则为 1，否则为 0，$rank_i$ 越小说明排序越靠前。

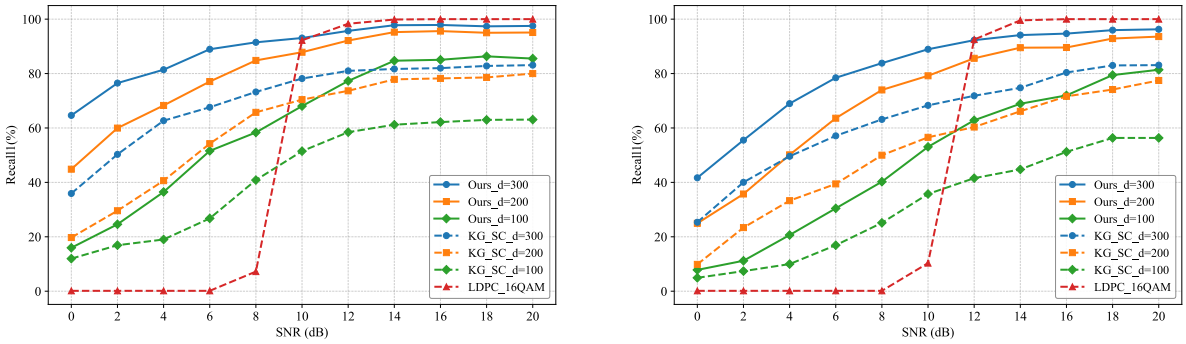
MRR 反映排名的连续变化：

$$\text{MRR} = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{rank_i} \tag{32}$$

表 3: 语义通信系统中各层指标及其作用

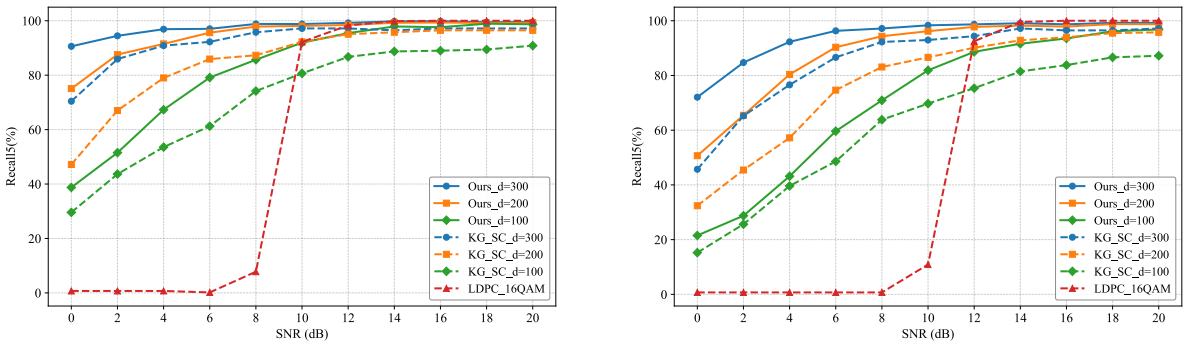
层级	指标	作用
语义空间底层	Fidelity	底层 embedding 是否重建成功?
排序质量层	MRR	语义排序质量到底有多高?
宽松任务层	Recall@5	宽松条件下 semantic retrieval 是否成功?
严格任务层	Recall@1	完全严格条件下 semantic retrieval 是否成功?

6.3 仿真实验结果



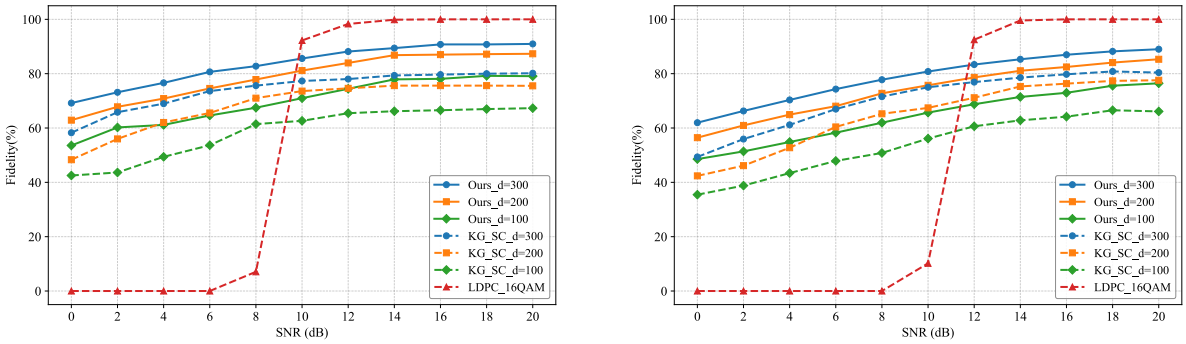
(a) AWGN (b) Rayleigh

图 2: Recall@1 in different SNR



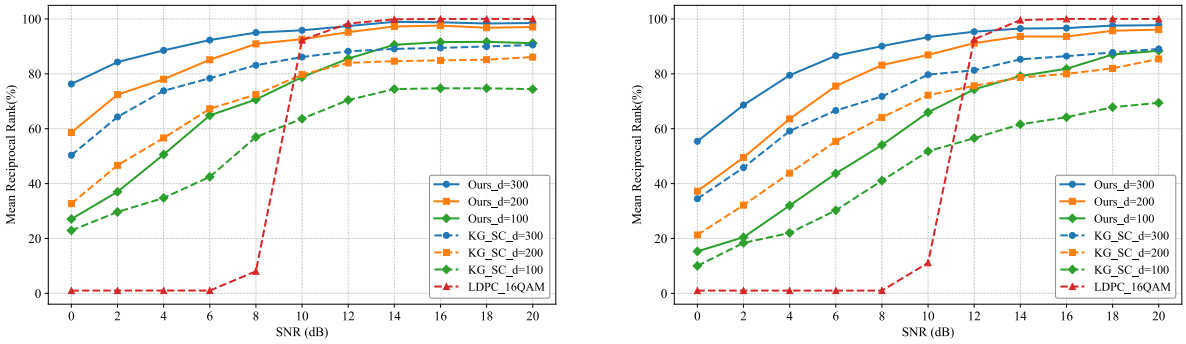
(a) AWGN (b) Rayleigh

图 3: Recall@5 in different SNR



(a) AWGN (b) Rayleigh

图 4: Fidelity in different SNR



(a) AWGN (b) Rayleigh

图 5: Mean Reciprocal Rank in different SNR

6.3.1 传统通信基线的语义映射方法

需要特别说明的是，本文对比的传统通信基线（LDPC）本身并不具备语义表达能力，其输出为逐比特恢复后的离散字符序列。为保证语义通信系统与传统通信基线在同一评价空间内进行比较，本文仅在评估阶段（该过程不参与任何模型训练）对 LDPC 系统译码后的字符串执行

统一的语义映射操作：首先将传统通信系统解调与译码得到的字符串序列输入至与语义通信系统相同的语义编码器（即用于产生语义嵌入的编码网络），从而获得对应的语义向量；随后再依据语义空间中的距离度量与检索机制，计算其 Fidelity、MRR 与 Recall@k 等语义级性能指标。

这种处理方式确保了两类系统在同一语义空间中进行比较，使得性能差异仅由通信设计本身造成，而不受语义表示方式差异的影响。实验结果显示，传统通信方案由于无法保证逐比特恢复的语义一致性，其映射后的语义向量在低 SNR 条件下往往呈现较大的语义偏差，从而导致语义性能指标显著劣于语义通信系统。

6.3.2 仿真实验结果分析

从实验结果的量化分析中可以观察到显著的性能规律。首先，语义通信系统表现出明显的维度敏感性，高维嵌入在对抗噪声方面具有决定性优势。以 AWGN 信道为例，在低信噪比区域（SNR $= 0$ dB），采用 $d = 300$ 维嵌入的系统在 Recall@1 任务上达到了约 **65%** 的准确率，相比于 $d = 100$ 的低维模型（约 **15%**）提升了近 **50** 个百分点。此外，任务的宽松度对命中率有显著增益，在同等信道条件下，Recall@5 指标相比 Recall@1 平均提升了约 **20** 个百分点，表明模型即使未能精确命中首位，也能将目标语义高概率地保留在候选列表的前列。

其次，对比不同信道条件下的表现可知，Rayleigh 衰落信道对语义恢复的挑战主要集中在低 SNR 区间。数据表明，在 SNR < 6 dB 时，Rayleigh 信道下的 MRR 和 Fidelity 指标平均比 AWGN 信道低大约 **8∼20** 个百分点。然而，所提出的 KG-EmPress 模型展现了良好的鲁棒性，随着 SNR 增大至 **10** dB 以上，两条曲线逐渐收敛，最终均能达到 **90%** 以上的饱和性能。这证实了即便在存在多径衰落的复杂信道中，只要信噪比达到中等水平，本方案仍能实现与高斯信道近似的高质量语义传输。

与现有基线方案的对比进一步验证了本系统的优越性。传统通信系统（LDPC_16QAM）呈现出明显的“悬崖效应”：在 SNR 低于 **6** dB 时，由于误码率超出纠错极限，其 Recall@1 与 MRR 指标迅速跌至 **0%**，完全丧失了语义恢复能力。相比之下，KG-EmPress 在此“盲区”内仍能维持有效的语义判别。同时，得益于 Highway 门控机制对关键特征的筛选，本方案在低 SNR 下的语义保真度（Fidelity）比采用固定压缩结构的 KG-SC 方案高出约 **10** 个百分点，证明了逐维语义路径选择在强噪声干扰下的有效性。

综上所述，实验结果充分证明，KG-EmPress 系统在底层语义恢复、排序一致性及检索任务上均显著优于传统 LDPC 方案与 KG-SC 基线。特别是在传统通信失效的低信噪比区域（0∼6 dB），高维模型凭借其强大的抗噪能力，实现了从“无”到“有”的语义通信突破，并在高 SNR 区域保证了极高的传输准确度与鲁棒性。